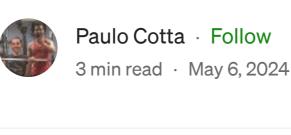
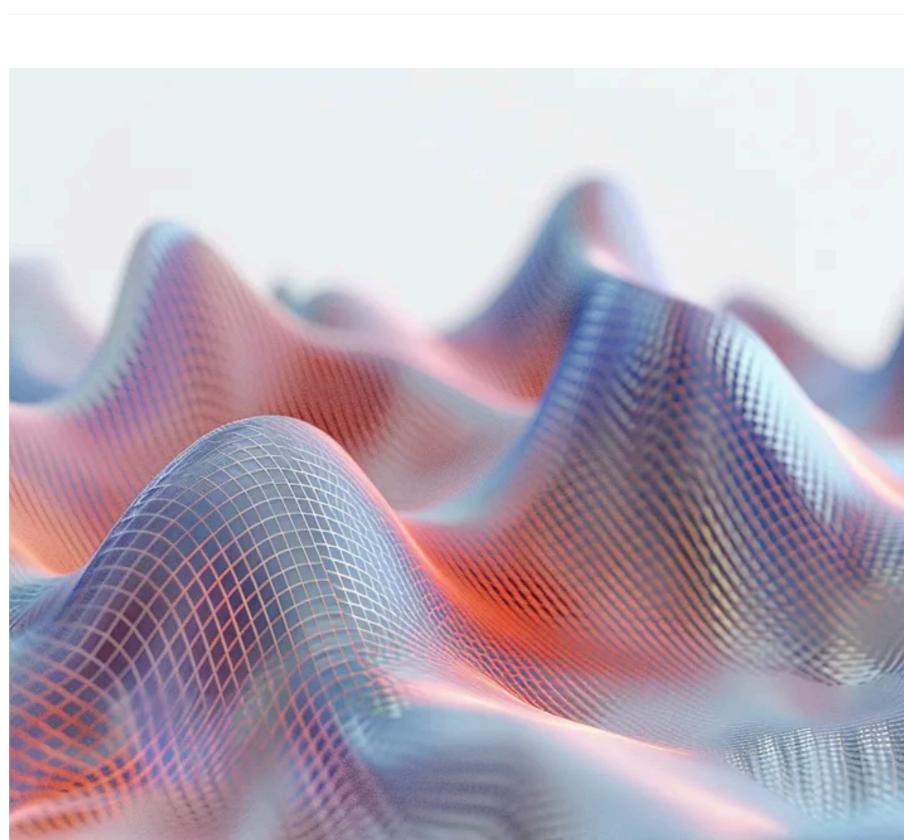
Medium

+ Get unlimited access to the best of Medium for less than \$1/week. Become a member

Introdução ao ARIMA e SARIMA: Modelos de Séries Temporais





fundamentais para análise e previsão de séries temporais. Esses modelos são amplamente utilizados em diversas áreas, como finanças, economia, meteorologia, entre outras, para entender e prever o comportamento de séries temporais. O que são Séries Temporais? Uma série temporal é uma sequência de observações de dados coletadas em intervalos de tempo regulares. Esses dados podem representar qualquer

Os modelos ARIMA (AutoRegressive Integrated Moving Average) e SARIMA

(Seasonal AutoRegressive Integrated Moving Average) são técnicas

temperatura diária, a demanda por um produto, entre outros.

componentes tem um papel específico:

Modelos ARIMA O ARIMA é um modelo estatístico que combina componentes de autoregressão (AR), média móvel (MA) e diferenciação (I). Cada uma dessas

fenômeno que varie ao longo do tempo, como o preço das ações, a

• Auto-regressão (AR): Refere-se à relação entre uma observação atual e

anteriores (q).

estacionária.

modelo AR (p). • Média Móvel (MA): Refere-se à relação entre uma observação e um erro residual de um modelo de média móvel aplicado a lags de observações

um número de observações anteriores (lags) conhecido como ordem do

la estacionária, ou seja, removendo tendências e sazonalidades. O ARIMA é definido pelos parâmetros pp, dd e qq, onde:

• Diferenciação (I): Refere-se à diferenciação da série temporal para torná-

• pp é a ordem do componente AR. • *dd* é o número de diferenciações necessárias para tornar a série

Modelo SARIMA O SARIMA é uma extensão do ARIMA que lida especificamente com

período sazonal ss. Os parâmetros adicionais são:

necessárias para tornar a série estacionária.

Implementação em Python

import pandas as pd

import numpy as np

np.random.seed(0)

import matplotlib.pyplot as plt

Gerar dados de exemplo

from statsmodels.tsa.statespace.sarimax import SARIMAX

from statsmodels.graphics.tsaplots import plot_acf, plot_pacf

• qq é a ordem do componente MA.

• Ordem sazonal AR (PP): O número de termos de auto-regressão sazonal. • Ordem sazonal MA (QQ): O número de termos de média móvel sazonal. • Diferenciação sazonal (DD): O número de diferenciações sazonais

componentes sazonais em séries temporais. Além dos parâmetros pp, dd e

qq, o SARIMA também inclui parâmetros sazonais PP, DD e QQ, bem como o

• Período sazonal (ss): O número de observações em uma temporada.

- A biblioteca statsmodels em Python fornece funcionalidades para ajustar
- modelos ARIMA e SARIMA. Vamos ver um exemplo de como implementar um modelo SARIMA em Python:

data = np.random.randn(100) index = pd.date_range('2024-01-01', periods=100, freq='D') series = pd.Series(data, index=index) # Plotar a série temporal plt.figure(figsize=(10, 6)) plt.plot(series) plt.title('Série Temporal de Exemplo') plt.xlabel('Data') plt.ylabel('Valor') plt.show() # Dividir os dados em treinamento e teste train_size = int(len(series) * 0.8) train, test = series[:train_size], series[train_size:] # Ajustar o modelo SARIMA order = (1, 1, 1)seasonal_order = (1, 1, 1, 12)model = SARIMAX(train, order=order, seasonal_order=seasonal_order) model_fit = model.fit(disp=False) # Fazer previsões predictions = model_fit.forecast(steps=len(test)) # Plotar previsões plt.figure(figsize=(10, 6)) plt.plot(test.index, test.values, label='Observado') plt.plot(test.index, predictions, color='red', label='Previsão') plt.title('Previsão com Modelo SARIMA') plt.xlabel('Data') plt.ylabel('Valor') plt.legend() plt.show() Neste exemplo, ajustamos um modelo SARIMA aos dados de treinamento e usamos o modelo para fazer previsões nos dados de teste. A ordem do modelo é especificada como (1,1,1) e a ordem sazonal é (1,1,1,12), o que significa que estamos incluindo um termo de auto-regressão, um termo de média móvel e uma diferenciação sazonal de ordem 1, juntamente com um

Conclusão Os modelos ARIMA e SARIMA são ferramentas poderosas para modelagem e previsão de séries temporais, permitindo entender e prever o comportamento de dados ao longo do tempo. Com a implementação adequada desses modelos, é possível fazer previsões precisas e tomar decisões informadas em uma variedade de aplicações.

Arima

5 Q

40 Followers

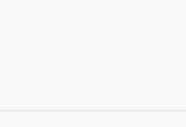
Sarima

Written by Paulo Cotta

https://www.linkedin.com/in/paulo-vitor-pereira-cotta/

Time Series Forecasting

componente sazonal de período 12.



Follow 🗠

Coleta de Dados ao Desenvolvimento da Interface Nos últimos anos, os avanços na área de inteligência artificial têm

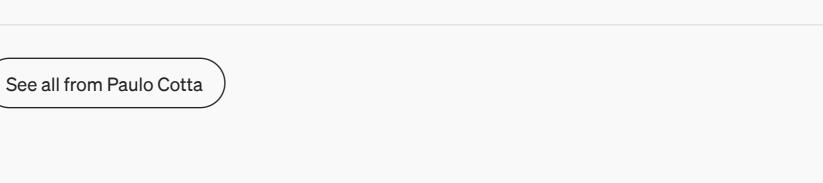
Paulo Cotta

More from Paulo Cotta

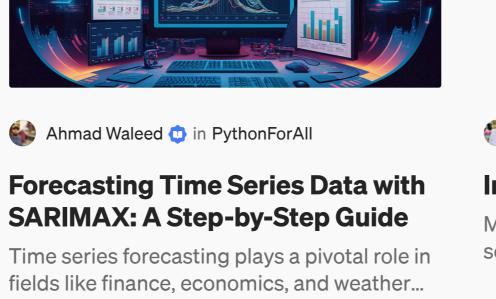
May 6 👋 3

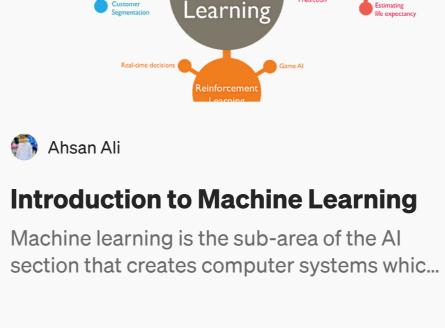
proporcionado o desenvolvimento de sistemas de...

Criando um Chatbot com LLAMA3: Da

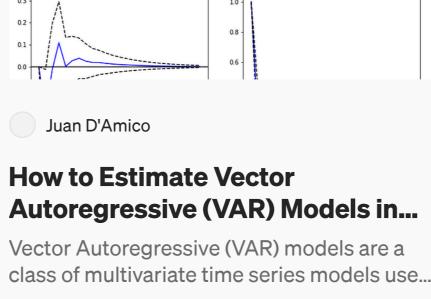


Recommended from Medium

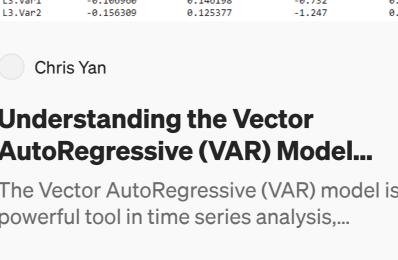




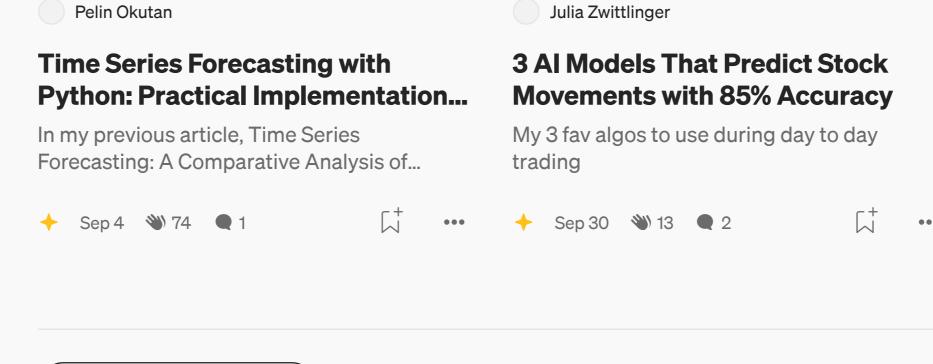
Lists



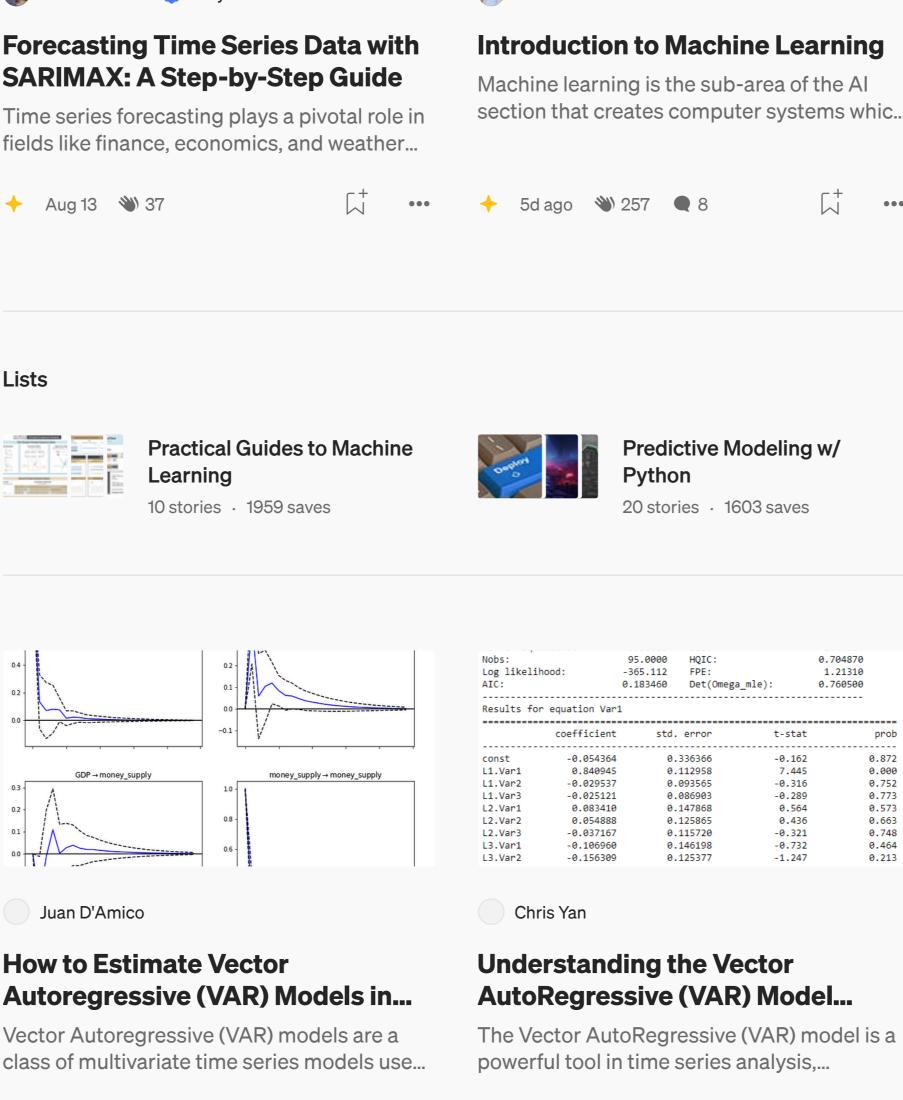
→ May 17 *** 16



+ Jul 31 **\extrm{\text{\ti}}\text{\tett{\text{\text{\text{\text{\text{\text{\text{\text{\text{\text{\text{\text{\text{\text{\text{\ti}\tint{\text{\text{\text{\text{\text{\text{\text{\text{\text{\text{\text{\text{\text{\texi}\text{\text{\text{\text{\text{\text{\texi}\text{\text{\text{\texi}}\\text{\text{\text{\text{\texi}\texitt{\text{\texi}\text{\texitit{\text{\texi}\text{\texitit}\\\ \tittt{\texititt{\texitit}\\\ \tittt{\texititt{\texi{\texi{\texi{\texit{\texi{\texi{\texi{\texi{\t**



Help Status About Careers Press Blog Privacy Terms Text to speech Teams



See more recommendations